



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE INGENIERÍA MECÁNICA
Y ELÉCTRICA UNIDAD CULHUACAN



INGENIERÍA EN COMPUTACIÓN

“SISTEMA DE DETECCIÓN DE EXPRESIONES FACIALES CLASIFICADAS EN
EMOCIONES MEDIANTE RNN-LSTM APLICADO PARA TELEMEDICINA”

QUE PARA OBTENER EL TÍTULO DE:
INGENIERO EN COMPUTACIÓN

AUTOR:

JOSÉ ARMANDO SOTELO BARRALES

ASESORA:

DRA. MARIKO NAKANO MIYATAKE

ASESOR:

DR. GIOVANNY SÁNCHEZ RIVERA

MÉXICO, 2024

Índice general

1. Introducción	5
1.1. Planteamiento del problema	5
1.2. Justificación	6
1.3. Objetivo general	7
1.4. Objetivos específicos	7
2. Estado del arte	8
3. Marco teórico	9
3.1. Inteligencia artificial	9
3.2. Aprendizaje automático	10
3.3. Aprendizaje profundo	10
3.4. Detección de rostros	12
3.5. Reconocimiento de emociones	12
3.6. Modelos de regresión lineal con redes neuronales	12
3.6.1. Los Fundamentos de las Redes Neuronales	12
3.6.2. Componentes de una Red Neuronal	13
3.7. Red Neuronal Recurrente tipo LSTM	14
4. Diseño e Implementación	15
5. Pruebas y resultados	21
6. Conclusiones	31
7. Anexo I. Viabilidad y Factibilidad	32
8. Anexo II. Normatividad	33
9. Anexo III. Hoja técnica	34
10. Anexo IV. Glosario	35
11. Anexo V. Acrónimos	36
12. Anexo VI. Línea de tiempo	37
13. Anexo VII. Cronograma	38
14. Anexo A	39
14.1. Aceptación de la videoconsulta	39
14.2. Anaconda Navigator y Python	39
14.3. Spyder	40
14.4. Librería Numpy	40
14.5. Librería Pytorch	40

14.6. Librería Matplotlib	41
14.7. Librería OpenCV	41
14.8. Librería Time	41
14.9. Librería Math	41
14.10. Librería os	42
14.11. Librería JSON	42
14.12. Librería scikit-learn	43
14.13. MediaPipe	43
14.14. Unidad de procesamiento de gráficos	44
14.15. CUDA	44
14.16. Distribución Gaussiana	44
15. Anexo B	45
15.1. Bases de datos	45
16. Referencias	46

Índice de figuras

3.1. Red Neuronal (Menacho Chiok, C. H., 2014).	13
3.2. Celda de RNN-LSTM (Ernesto Fabregas, 2019).	14
4.1. Diagrama de bloques procesamiento de la información.	15
4.2. Ubicación de los 468 puntos de face mesh.	16
4.3. Ecuaciones.	16
4.4. Diagrama de flujo de extracción de características en diferentes tiempos.	17
4.5. Diagrama de flujo de Distribución Gaussiana.	18
4.6. Diagrama de flujo Red neuronal recurrente de memoria de largo plazo a corto plazo.	19
4.7. Bloque de implementación.	20
5.1. Primer punto clave.	22
5.2. Segundo punto clave.	22
5.3. Tercer punto clave.	22
5.4. Cuarto punto clave.	22
5.5. Quinto punto clave.	22
5.6. Sexto punto clave.	22
5.7. Séptimo punto clave.	23
5.8. Octavo punto clave.	23
5.9. Noveno punto clave.	23
5.10. Décimo punto clave.	23
5.11. Extracción de las 20 características.	23
5.12. Primer punto clave ángulo alfa.	24
5.13. Primer punto clave ángulo beta.	24
5.14. Segundo punto clave ángulo alfa.	24
5.15. Segundo punto clave ángulo beta.	24
5.16. Tercer punto clave ángulo alfa.	24
5.17. Tercer punto clave ángulo beta.	24
5.18. Cuarto punto clave ángulo alfa.	25
5.19. Cuarto punto clave ángulo beta.	25
5.20. Quinto punto clave ángulo alfa.	25
5.21. Quinto punto clave ángulo beta.	25
5.22. Sexto punto clave ángulo alfa.	25
5.23. Sexto punto clave ángulo beta.	25
5.24. Séptimo punto clave ángulo alfa.	26
5.25. Séptimo punto clave ángulo beta.	26
5.26. Octavo punto clave ángulo alfa.	26
5.27. Octavo punto clave ángulo beta.	26
5.28. Noveno punto clave ángulo alfa.	26
5.29. Noveno punto clave ángulo beta.	26
5.30. Décimo punto clave ángulo alfa.	27
5.31. Décimo punto clave ángulo beta.	27
5.32. Distancia entre las 3 clases.	27

5.33. Primer aprendizaje.	28
5.34. Primera matriz de confusión.	28
5.35. Segundo aprendizaje.	28
5.36. Segunda matriz de confusión.	28
5.37. Tercer aprendizaje.	28
5.38. Tercera matriz de confusión	28
5.39. Visualización de datos de prueba en matriz de confusión.	29
5.40. Exactitud	29
5.41. Emoción enojo.	30
5.42. Emoción felicidad.	30
5.43. Emoción tristeza.	30
9.1. Especificaciones de la GPU.	34
12.1. Línea de tiempo.	37

Capítulo 1

Introducción

El progreso de la telemedicina desde el surgimiento del virus COVID-19, informado por el Centro Nacional de Excelencia Tecnología en Salud, muestra un notable aumento debido al incremento en el uso del servicio. Dentro del sistema de telemedicina en México, se puede implementar un sistema de identificación de expresiones faciales para clasificarlas en emociones, reconociendo la importancia de estas en la experiencia humana. Las emociones, representadas a través de gestos faciales, son una parte esencial de la existencia humana, impactando la salud y desempeñando un papel crucial en el aprendizaje, la creatividad y las interacciones sociales. Se propone un sistema de reconocimiento de emociones mediante la detección de expresiones faciales clasificadas en emociones utilizando una red neuronal recurrente tipo memoria a largo plazo a corto plazo (RNN-LSTM) aplicada a la telemedicina.

1.1. Planteamiento del problema

La telemedicina experimenta un incremento significativo en la industria médica. A lo largo de los años, la inversión económica y el aumento de usuarios impulsan la creación de sistemas que mejoran la atención médica continua. Dado que el médico no puede supervisar constantemente al paciente, por ejemplo, su rostro, y no identifica emociones negativas persistentes, esto puede reducir la capacidad de recuperación, empeorar su salud y generar otras enfermedades. Actualmente, pocos sistemas de reconocimiento de emociones se implementan en hospitales, y la mayoría utiliza redes neuronales que clasifican datos no temporales.

La tristeza aumenta el estrés y afecta la hormona cortisol, fundamental en el control de los niveles de azúcar en la sangre, la presión sanguínea y la calidad del sueño. Esto la convierte en el estado psicológico más perjudicial para la salud (Lupayante, 2016). Está relacionada con:

- Cardiopatías. Así lo afirma este estudio realizado por la Universidad de Caldas (Colombia).
- Tanto el estrés como la depresión pueden favorecer la precipitación de una enfermedad y agravarla. Cuando una persona está estresada o extremadamente triste, puede observar cómo su cuerpo no funciona con regularidad.
- Las defensas de una persona bajan y el riesgo de caer enfermo aumenta considerablemente cuando se encuentra bajo estrés o depresión, según afirma una investigación publicada por la Revista Chilena de Neuro-Psiquiatría.

El enojo en una persona puede tener un impacto directo en la salud del corazón, ya que el estrés está estrechamente relacionado con enfermedades cardiovasculares. Algunos efectos del enojo en el cuerpo incluyen (ACHS, 2012):

- Incremento de la presión arterial, lo que con el tiempo puede dañar las arterias.
- Aumento del ritmo cardíaco y desarrollo de taquicardia.
- Producción elevada de sustancias químicas como la adrenalina, perturbando el equilibrio natural del cuerpo.
- Aparición de contracturas musculares, dolores y migrañas.
- Mayor riesgo de sufrir enfermedades como gastritis, colitis y dermatitis.

1.2. Justificación

CENETEC reporta que en 2022 el total de atenciones a distancia fue de 1,977,310 consultas, durante enero a diciembre de 2022 destacan la interpretación diagnóstica con 664,141 acciones, la asesoría médica a distancia por COVID-19 con 336,188 y el seguimiento a distancia por COVID-19 con 312,167 (CENETEC, 2022).

La industria de la salud no se detiene, sino que su demanda crece exponencialmente, y la telemedicina se convierte en una alternativa focalizada en cuidar de la salud sin exponerse al virus en clínicas y hospitales. Su popularidad crece con el pasar de los meses en los que las visitas no urgentes a clínicas y hospitales no son recomendables. Esto motiva el nacimiento de servicios que facilitan el proceso de agendar citas, ubicar profesionales de la salud que ofrecen este tipo de servicio y, en general, impulsa esta rama de la industria. Por ello, se destacan el concepto y cifras importantes de esta industria, que son una pequeña muestra del crecimiento exponencial que experimenta al iniciar la pandemia y ahora se convierte en una considerable idea para invertir. La popularidad de la telemedicina en números, según el Centro para el Control y Prevención de Enfermedades (CDC), registra en Estados Unidos un aumento del 150 % en consultas a través de la telemedicina para el primer trimestre del 2020. SingleCare reporta que, en Asia y el Pacífico, las aseguradoras afirman haber registrado un aumento del 52 % en el uso de estos servicios, aumentando del 4 % al 56 %. India, por su parte, predice un aumento del 31 % del mercado de la telemedicina para el 2025. En cuanto a Europa, Statista reporta que los 5 países que ven un crucial incremento en el uso de la telemedicina son España, Eslovenia, Polonia, Irlanda y Lituania. En cuanto al valor del mercado a nivel mundial, Fortune Business Insight estima un crecimiento considerable que va desde USD 90,74 mil millones en 2021 a USD 636,38 mil millones para el 2028 (A. Daly Aurenty, 2022). Para reconocer las emociones de una persona a través del vídeo, es necesario analizar los cambios temporales en cada parte del rostro. Las redes neuronales recurrentes, como LSTM, se diseñan para el análisis de datos de diferente tiempo, ya que las redes neuronales CNN solo clasifican los datos no temporales. Cada red neuronal tiene su propósito. Las aplicaciones en las que las CNN son particularmente útiles incluyen la detección de rostros, el descubrimiento de fármacos y el análisis de imágenes, dijo Arikala. Los RNN-LSTM son útiles para la traducción de idiomas, la inteligencia conversacional y el análisis de sentimientos.

1.3. Objetivo general

Desarrollar un sistema de detección de expresiones faciales y clasificarlas mediante la Red Neuronal Recurrente de tipo memoria a largo plazo a corto plazo (RNN-LSTM) en felicidad, enojo y tristeza, para ayudar al médico a identificar las emociones de los pacientes por video.

1.4. Objetivos específicos

1. Analizar 4 bases de datos de videos de expresiones faciales de actores y actrices y recopilar la información que necesitamos para extraer los datos de interés separando en 3 carpetas que son enojo, felicidad y tristeza.
2. Diseñar un entorno virtual mediante Anaconda Navigator con Python y las librerías Mediapipe, Matplotlib, OpenCV, math y os. Para programar un algoritmo que extraiga las características de las expresiones faciales en vectores etiquetados y guardarlos en un archivo JSON para poder entrenar la red neuronal.
3. Programar con Python, Librería Numpy, Matplotlib y JSON, un algoritmo que justifique por qué tomamos ciertas zonas clave del rostro para extraer las características utilizando la distribución de Gaussiana.
4. Generar otro entorno virtual para la tarjeta gráfica, Anaconda Navigator con Python y la librería Pytorch para implementar una RNN-LSTM y entrenarla con los archivos de formato JSON, para poder clasificar las características de expresiones en emociones, tristeza, felicidad y enojo.
5. Realizar pruebas y validaciones en el modelo entrenado de la RNN-LSTM para observar los resultados y ajustar la red neuronal.

Capítulo 2

Estado del arte

Se presenta un trabajo que explica la relevancia del aprendizaje profundo para el reconocimiento en tiempo real mediante el uso del método de CNN (Convolutional Neural Network). Se describe el método Convolutional Neural Networks, utilizando la base de datos FER 2013 en imágenes de 48x48 píxeles, con un 84.16 % precisión. En consecuencia, este documento proporciona un procedimiento para identificar emociones (Sultana, A., Dey, S. K., & Rahman, M. A. 2021).

Se presenta un trabajo que describe un sistema de reconocimiento de emociones a través de información y entretenimiento para un hospital. El reconocimiento de afectos se realiza utilizando una base pública JAFFE, compuesta por 214 imágenes de 256 píxeles en escala de grises para validar, y el resto para entrenar. Utilizan como herramienta un clasificador K Star, obteniendo una exactitud del 93.42 % en un primer escenario (Kallipolitis, A., Galliakis, M., Menychtas, A., Maglogiannis, I., 2019).

Se presenta un trabajo que proponen un modelo de red neuronal convolutiva (CNN) para reconocer la emoción junto a sus colaboradores. El modelo se desarrolla en una nube durante el lapso de tiempo libre y se descarga en un servidor de bordes. Durante la prueba, un dispositivo final como un teléfono captura una imagen facial y realiza un preprocesamiento, que incluye detección de rostros, recortes faciales, mejora de contraste y redimensionamiento de imágenes. La imagen preprocesada se adjunta al servidor de bordes. El servidor de bordes ejecuta el modelo CNN e infiere una decisión sobre la emoción. La determinación se transmite posteriormente al dispositivo móvil. Para la evaluación se utilizan dos conjuntos de datos, JAFFE y Cohn-Kanade extendido (CK.). Los resultados experimentales revelan que el sistema sugerido es eficiente energéticamente, con parámetros menos aprables y una buena precisión de reconocimiento. El 93,5 % de exactitud con los conjuntos de datos JAFFE y CK es del 93,5 % y del 96,6 %, respectivamente (Muhammad, G., & Hossain, M. S., 2021).

Capítulo 3

Marco teórico

3.1. Inteligencia artificial

La inteligencia artificial (IA) es la capacidad de las computadoras para aprender información y tomar decisiones como los seres humanos. Más concretamente, se define como la capacidad de las máquinas de utilizar algoritmos, aprender de los datos y tomar decisiones basadas en ese aprendizaje. A diferencia de los humanos, los dispositivos de IA no necesitan pausas y pueden procesar múltiples mensajes simultáneamente, además de tener tasas de error más bajas que las máquinas comparables. La idea de que las computadoras o programas pueden aprender y tomar decisiones es crucial y relevante, ya que ese proceso crece exponencialmente con el tiempo. Gracias a estas capacidades, los sistemas de IA realizan muchas tareas antes exclusivas de los humanos. Las tecnologías basadas en IA se utilizan actualmente para ayudar a las personas a lograr mejoras significativas y mayor eficiencia en casi todos los ámbitos de la vida. Sin embargo, el crecimiento de la IA también exige cautela, prevención y análisis de las desventajas directas e indirectas que puede traer su uso generalizado. La IA se puede utilizar en casi cualquier situación. Algunas de las aplicaciones tecnológicas de la IA que están creciendo rápidamente en la actualidad incluyen (Rouhiainen, L. 2018):

- Reconocimiento de imágenes estáticas, clasificación y etiquetado: estas herramientas son útiles para una amplia gama de industrias.
- Mejoras del desempeño de la estrategia algorítmica comercial: ya ha sido implementada de diversas maneras en el sector financiero.
- Procesamiento eficiente y escalable de datos de pacientes: esto ayudará a que la atención médica sea más efectiva y eficiente.
- Mantenimiento predictivo: otra herramienta ampliamente aplicable en diferentes sectores industriales.
- Detección y clasificación de objetos: puede verse en la industria de vehículos autónomos, aunque también tiene potencial para muchos otros campos.
- Distribución de contenido en las redes sociales: se trata principalmente de una herramienta de marketing utilizada en las redes sociales, pero también puede usarse para crear conciencia entre las organizaciones sin ánimo de lucro o para difundir información rápidamente como servicio público.
- Protección contra amenazas de seguridad cibernética: es una herramienta importante para los bancos y los sistemas que envían y reciben pagos en línea.

3.2. Aprendizaje automático

El aprendizaje automático es uno de los principales enfoques de la inteligencia artificial. En pocas palabras, este es un aspecto de la informática en el que las computadoras y las máquinas pueden aprender sin ser programadas. Los resultados típicos son sugerencias o predicciones para situaciones específicas. Las primeras computadoras personales que estuvieron disponibles para los consumidores en la década de 1980 estaban programadas explícitamente para efectuar acciones específicas. Por el contrario, gracias al aprendizaje automático, muchos de los dispositivos que se ven en el futuro obtienen experiencia y conocimiento de cómo se utilizan y brindan experiencias de usuario personalizadas. Ejemplos de ello en la actualidad son la personalización de los sitios de medios sociales como Facebook o los resultados del motor de búsqueda de Google. El aprendizaje automático usa algoritmos para aprender de los patrones de datos. Por ejemplo, los filtros de spam de correo electrónico utilizan este tipo de aprendizaje con el fin de detectar qué mensajes son correo basura y separarlos de aquellos que no lo son. Este es un sencillo ejemplo de cómo los algoritmos pueden usarse para aprender patrones y utilizar el conocimiento adquirido para tomar decisiones. Es un avance importante dando nuevas herramientas, implementaciones así mejorando la productividad de actividades tanto como laborales incluyendo la mayoría de las disciplinas logrando eficacia, también se puede utilizar para la vida no laboral como consecuencia mejorar la calidad de vida (Rouhiainen, L. 2018).

3.3. Aprendizaje profundo

Una de las áreas más dinámicas y en crecimiento de la inteligencia artificial es el aprendizaje profundo. Esta es una parte del aprendizaje automático que se utiliza para resolver problemas complejos que involucran grandes cantidades de datos. El aprendizaje profundo se produce mediante el uso de redes neuronales, que se componen de capas, para reconocer relaciones y patrones complejos en los datos. Sus aplicaciones requieren grandes cantidades de información y una potente potencia de procesamiento. Actualmente, se utiliza en reconocimiento de voz, procesamiento del lenguaje natural, visión por computadora e identificación de vehículos en sistemas de asistencia al conductor. Un claro ejemplo de esto se puede ver en Facebook, traductores, y recientemente ha quedado claro que esto se puede hacer gracias al aprendizaje profundo. Suelen ser segmentos de texto breves, como actualizaciones de estado, que los usuarios publican en sus perfiles. Sin aprendizaje profundo, sería costoso y requeriría un gran equipo para brindar el mismo servicio (Rouhiainen, L. 2018).

-Acceso a los datos

En el mundo moderno, se tienen a disposición grandes cantidades de datos. En contraste, hace 30 años, no se disponía de tanta información sobre atención médica, transporte, finanzas y otras industrias críticas, lo que hacía imposible encontrar soluciones basadas en inteligencia artificial a problemas fundamentales en estas áreas. Es lógico pensar que la tecnología que se utiliza hoy será aún más poderosa dentro de 10 años debido a un mejor acceso a los datos. Los ejemplos incluyen el desarrollo de vehículos autónomos y ciudades inteligentes conectadas. El componente subyacente que hace esto posible es la cantidad de datos que se pueden recopilar y analizar para mejorar el rendimiento de los sistemas de IA (Rouhiainen, L. 2018).

-Tipos de datos

El análisis de datos normalmente se basa en dos tipos de información: datos estructurados y datos no estructurados. Para comprender verdaderamente los sistemas de IA, es importante reconocer la diferencia entre estos dos tipos de datos. Tradicionalmente, los datos estructurados se utilizan con más frecuencia que los no estructurados. El primero implica ingresar información como números, fechas, monedas y direcciones. El último incluye tipos de datos que son más complejos de analizar, como texto, imágenes y vídeos. Sin embargo, los avances en inteligencia artificial han hecho posible examinar más datos no estructurados y utilizar los resultados para hacer recomendaciones y predicciones (Rouhiainen, L. 2018).

-Uso de datos en los negocios y la sociedad

Grandes cantidades de datos o big data también pueden ayudar a las grandes empresas a mejorar los procesos internos y externos. Kai-Fu Lee, capitalista de riesgo y director ejecutivo de Sinovation Ventures, explica por qué los datos son tan importantes para las grandes empresas de tecnología al describir los cinco pasos necesarios para perfeccionar una solución de inteligencia artificial. Aunque utiliza el ejemplo de una empresa de tecnología estadounidense, estos pasos también se pueden aplicar a otras empresas internacionales que dependen de la IA, como Alibaba, Baidu y Tencent. Aquí están los pasos (Rouhiainen, L. 2018):

1. Obtener más datos: la idea clave de este paso es que las empresas de tecnología pueden crear servicios tan útiles que las personas están dispuestas a permitir que sus datos se utilicen en el servicio. Un ejemplo de ello es el buscador Google, que abarca una gran cantidad de datos. De manera similar, Facebook no sería una red social tan poderosa si no tuviera acceso a información sobre las tendencias sociales de sus usuarios.
2. Aprovechar la IA para mejorar productos: empresas como Google y Facebook utilizan la IA para mejorar sus productos, personalizando la experiencia del usuario y haciéndola importante y relevante para los usuarios.
3. Mayor número de usuarios: cuando las personas tienen una experiencia satisfactoria con un producto o servicio, es más probable que lo recomienden a un amigo.
4. Mayores ingresos: más usuarios casi a menudo significa más ingresos.
5. Más expertos y científicos en IA: a medida que las empresas aumentan sus ingresos, pueden atraer a los mejores expertos y científicos en IA. Cuanto más tiempo trabajan para una empresa los científicos de datos y los expertos en aprendizaje automático, más importante se vuelve la investigación en IA, lo que hace que la empresa no solo sea más valiosa sino también mejor preparada para el futuro.

Dado que los datos son un elemento tan crítico en el desarrollo de la IA, muchos expertos están pidiendo a las principales empresas de tecnología que pongan algunos de sus datos a disposición del público para que más empresas puedan utilizarlos en sus aplicaciones y productos. Aunque esta idea es cuestionable, está claro que tener esos datos a mano es esencial para un mayor desarrollo de futuros productos y servicios de inteligencia artificial (Rouhiainen, L. 2018).

Sin duda, cuando la inteligencia artificial se implementa más en diferentes lugares, en el futuro mediano los procesos que constituyen la sociedad para diferentes países se ven afectados, ya que la interacción con la tecnología es diferente. Como cuando los celulares y el internet cambiaron la manera de comunicarse e interactuar con la tecnología, habrá de nuevo un cambio que afecta, si no también, la cultura (Rouhiainen, L. 2018).

3.4. Detección de rostros

El reconocimiento facial en imágenes se considera el punto de partida para una variedad de aplicaciones, incluidas aquellas centradas en la interacción persona-computadora y la visión por computadora. Este aspecto no es un campo nuevo. En los años 90 se publican una gran cantidad de algoritmos y aplicaciones siguiendo este aspecto. El trabajo realizado por proporcionar una excelente visión general del trabajo relacionado en la última década y propone dividir los algoritmos en cuatro categorías generales. Basados en conocimiento: teniendo como base lo que los seres humanos consideran como una cara; estos métodos identifican relaciones entre características del rostro. Aproximaciones basadas en características invariantes: la atención se centra en identificar características estructurales que no cambian independientemente de la forma, como la luz, el ángulo o la consistencia. Basados en comparación de plantillas: la imagen del rostro y sus características se comparan con patrones de muestra para reconocer. Basados en apariencia: a diferencia del algoritmo anterior, este algoritmo crea un modelo de forma de rostro basado en la imagen de prueba; se utiliza para encontrar rostros en ciertos grupos de imágenes (Pinzón Montes, Q. A., 2021).

3.5. Reconocimiento de emociones

Existen dos métodos para implementar un sistema de clasificación: supervisado y no supervisado. Para las emociones, las agrupaciones se deciden en función de las características de personalidad que es necesario identificar, por lo que se utiliza un método de clasificación. Es necesario primero comprender los grupos de categorías y considerar grupos creados a partir de dos partes: parte de capacitación y parte de validación. En el método de reconocimiento de patrones se consideran métodos como SVM, árbol de decisión, red bayesiana, algoritmo de sondeo, modelo oculto de Markov y red neuronal artificial, es decir, se consideran los criterios de clasificación, las llamadas categorías y categorías basadas en IA. Actualmente, se realizan ambas fases (detección de rostro y reconocimiento de patrones) en un solo paso, empleando herramientas como aprendizaje profundo (deep learning), utilizando redes neuronales de numerosas capas. Sin embargo, cuando la tarea a desarrollar es sencilla, emplear una herramienta robusta puede no ser una opción recomendable desde la perspectiva de complejidad computacional contra complejidad de la tarea a ser desarrollada. Es importante destacar que el porcentaje de exactitud de los algoritmos puede variar al hacer uso de diferentes conjuntos de datos para su entrenamiento (Pinzón Montes, Q. A., 2021).

3.6. Modelos de regresión lineal con redes neuronales

3.6.1. Los Fundamentos de las Redes Neuronales

Las Redes Neuronales Artificiales (RNA) son modelos computacionales y matemáticos que se inspiran en sistemas biológicos, adaptándolos y simulándolos en entornos computacionales. Estas redes surgen como un intento de emular las características del cerebro humano. Las RNA consisten en un conjunto de elementos simples, llamados neuronas, que se interconectan de manera masiva, operando en paralelo y con una organización jerárquica. Además, estas redes neuronales artificiales son modelos que permiten describir una amplia gama de fenómenos del mundo real y pueden ser comparados y aplicados junto con modelos estadísticos en problemas de predicción, clasificación y agrupamiento (Menacho Chiok, C. H., 2014).

3.6.2. Componentes de una Red Neuronal

Una RNA se compone de unidades de procesamiento simples, conocidas como neuronas, que están conectadas entre sí y a través de las cuales se transmite la información necesaria para su funcionamiento. El modelo de una RNA se basa en la estructura de un grafo dirigido, en el cual los nodos representan las neuronas y están interconectados mediante arcos dirigidos. Cada arco dirigido establece una relación entre los nodos y lleva asociado un peso numérico que determina la fuerza y la polaridad de la conexión, lo que facilita la propagación de la activación de una neurona hacia otra. En la Figura 3.1 se muestra el esquema de una red neuronal, donde hay n neuronas en la capa de entrada, m neuronas en la capa oculta y una neurona en la capa de salida (Menacho Chiok, C. H., 2014).




Figura 3.1: Red Neuronal (Menacho Chiok, C. H., 2014).

Las neuronas son los elementos o unidades de procesamiento de una RNA. Cada neurona i -ésima en cada instante tiene un valor numérico o estado de activación. Cada neurona puede tener múltiples entradas y opcionalmente una entrada constante (sesgo o umbral). Conexiones entre neuronas. Las neuronas artificiales están conectadas a través de arcos dirigidos. Cada arco dirigido tiene asociado un peso numérico que es el parámetro que refleja la influencia y fuerza de la sinapsis de la conexión (Menacho Chiok, C. H., 2014).

- Si es positivo, indica que la interacción (sinapsis) entre la neurona y es inactivada; es decir, siempre que la neurona esté desactivada, la neurona recibirá una señal de que tenderá a activarla.
- Si es negativo, la sinapsis es inhibitoria; lo cual indica que si está activada, enviará una señal a que tenderá a desactivarla.
- Si es cero, se supone que no hay conexión entre ambas neuronas. Las neuronas se organizan por niveles o capas con un número determinado de neuronas en cada una de ellas y que describen la forma en que estas se interconectan entre sí. En una RNA, se pueden distinguir tres tipos de capas:
 - Capa de entrada. Es la capa cuyos nodos (inputs) reciben directamente la información proveniente de las fuentes externas de la red (variables de entrada).
 - Capas ocultas. Son internas a la red y no tienen contacto directo con el entorno exterior. Las neuronas de esta capa pueden estar interconectadas de distintas maneras, lo que determina, junto con su número, las diferentes topologías de las RNN.
 - Capa de salida. Los nodos (outputs) de esta capa permiten realizar la transferencia de información de la red hacia el exterior (variables de salida).

3.7. Red Neuronal Recurrente tipo LSTM

Estructuras de arquitectura como las redes neuronales recurrentes del año 2002, se utilizan para modelar series temporales en las que las neuronas están completamente conectadas y tienen ciclos que alimentan las funciones de activación de los pasos anteriores como entradas. Esto denota un estado oculto de alta dimensión que les permite recordar información pasada. A pesar de su potencial, esta arquitectura mostró previamente un problema de gradientes de desvanecimiento/explotación (Bengio, Simard, Frasconi, 1994) que causó una disminución en el interés. Sin embargo, en los últimos años, se ha diseñado una nueva arquitectura para RNNs (Bengio et al., 2013, Hochreiter y Schmidhuber, 1997) llamada memoria a largo plazo (LSTM). La solución basada en los llamados bloques de la memoria ha superado el problema de la desaparición/explosión. Las unidades de puerta de entradas multiplicativas aprenden a abrirse o cerrarse en respuesta al error constante, que se aplica a través del tiempo por un error constante llamado carrusel de error constante, haciendo local LSTM tanto espacial como temporalmente. LSTM también ha resuelto retrasos cronológicos largos complejos utilizando las cualidades citadas anteriormente (Bitzel Cortez, Jae-Yoon Jung, Young-Jin Kim, Berny Carrera, Eds, 2017).




Figura 3.2: Celda de RNN-LSTM (Ernesto Fabregas, 2019).

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{Puerta de olvido})$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{Puerta de entrada})$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (\text{Valores candidatos})$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (\text{Actualización del estado de la celda})$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{Puerta de salida})$$

$$h_t = o_t \cdot \tanh(C_t) \quad (\text{Salida de la celda})$$

- Puerta de entrada: regula el flujo de nuevas informaciones, empleando una función de activación sigmoidea para discernir que datos retener y cuáles desechar.
- Puerta de olvido: administra el flujo de información proveniente del paso temporal anterior que requiere ser olvidada. También se vale de una función de activación sigmoidea para determinar qué datos deben ser descartados.
- Puerta de salida: controla la salida de información. Utiliza tanto una función de activación sigmoidea como una función de tangente hiperbólica para decidir qué datos deben ser transmitidos.

Capítulo 4

Diseño e Implementación

La Figura 4.1 muestra el proceso del proyecto.




Figura 4.1: Diagrama de bloques procesamiento de la información.

La Figura 4.1 muestra que la entrada es la información que la red neuronal utiliza para aprender. Se detecta la información con face mesh y se generan las características (datos) con la distancia euclidiana y ley de cosenos. Se continúa con el entrenamiento de los modelos y se evalúa la exactitud, evaluación y pruebas.

Face Mesh tiene 468 puntos faciales, pero solo se enfoca en 22 de ellos, los cuales se pueden encontrar en el Anexo B.





Figura 4.2: Ubicación de los 468 puntos de face mesh.

Sean los puntos $P_1(x_1, y_1)$ y $P_2(x_2, y_2)$ en el plano cartesiano. La distancia entre puntos se puede calcular utilizando la fórmula de la distancia euclidiana:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

La Figura 4.3 muestra la ley de cosenos. Al aplicarla, se obtienen las características (ángulos independientes). Conociendo todos los lados del triángulo, se pueden calcular estos ángulos, a los cuales se les asignan los nombres de alfa y beta.



Ley de cosenos

$$a^2 + b^2 - 2ab\cos C = c^2$$

$$b^2 + c^2 - 2bc\cos A = a^2$$

$$a^2 + c^2 - 2ac\cos B = b^2$$

Figura 4.3: Ecuaciones.

En la Figura 4.4 se observa el procedimiento de conservar las características extraídas de los vídeos. Una característica se almacena en un vector de tamaño 100 y se identifica por un diccionario alfanumérico. Por ejemplo, el número 0 representa la expresión de enojo, el número 1 representa la felicidad, y el número 2 representa la tristeza.




Figura 4.4: Diagrama de flujo de extracción de características en diferentes tiempos.

La distribución Gaussiana, también conocida como distribución normal, es una distribución de probabilidad continua que describe la distribución de valores a partir de un valor promedio. Se distingue por su forma de campana, en la que la mayoría de los valores se concentran cerca del promedio y la probabilidad de valores extremos disminuye a medida que se alejan de él.




Figura 4.5: Diagrama de flujo de Distribución Gaussiana.

El centroide proporciona una idea de la ubicación central del conjunto de datos. Es un valor único que resume la distribución espacial de los puntos. En el caso de datos bidimensionales, el centroide representa un punto que se encuentra en el centro de la distribución de los puntos.

La varianza es una medida de la dispersión o variabilidad de un conjunto de datos. Indica qué tan dispersos están los valores alrededor de su media (promedio). Una varianza alta implica que los valores están más dispersos, mientras que una varianza baja indica que los valores están más agrupados alrededor de la media.

La Figura 4.6 tiene en total 1500 datos, los cuales se usa el 20 % de los 1500 para pruebas y los datos restantes para entrenar la red. Luego se asigna el tamaño de lote, se refiere al subconjunto de los datos para que en el número de épocas se refiere al número de veces que se recorre todo el conjunto de datos de entrenamiento. El tamaño de lote, por otro lado, controla cuántos datos se procesan simultáneamente en cada iteración de entrenamiento. Cuando se tienen los parámetros pasa a entrenar, usa capa de RNN-LSTM. Y una lineal para clasificar. Y con los datos de prueba evalúa lo que aprendió y se guarda el modelo entrenado en .pth si es necesario se puede volver a entrenar cambiando los parámetros de tamaño de lote y épocas en el diagrama de flujo se muestra de manera general como funciona el entrenamiento.




Figura 4.6: Diagrama de flujo Red neuronal recurrente de memoria de largo plazo a corto plazo.

En la Figura 4.7, se muestra el modelo entrenado implementado en la computadora personal del médico.




Figura 4.7: Bloque de implementación.

Para la implementación ya no se utiliza la GPU, sino la CPU, debido a que hay computadoras que no tienen tarjeta gráfica. Esto provocaría que no se pueda utilizar el sistema de detección de expresiones faciales. Para poder implementar el modelo entrenado, se necesita replicar los mismos hiperparámetros. Para realizar las pruebas, se utiliza la cámara web, ingresando nueva información y detectando de la misma manera con face mesh. Luego, se generan los conjuntos de los mismos puntos clave y el modelo evalúa a qué clase pertenece.

Capítulo 5

Pruebas y resultados

El Cuadro 5.1 muestra 4 bases de datos (MSP-IMPROV, RAVDESS, CREMA-D y Ryerson Emotion DB) con las siguientes características: vídeo de 4 segundos, 500 vídeos por emoción, 30 cuadros por segundo, actores y actrices llevan a cabo el gesto facial y el vídeo debe estar en formato MP4.

Cuadro 5.1: Descripción de bases de datos de emociones.

BASES DE DATOS				
Bases de datos	MSP-IMPROV	RAVDESS	CREMA-D	Ryerson Emotion DB
Año de publicación	2017	2018	2020	2021
Autor	Carlos Busso	Livingstone SR	David Cooper	Ryerson Multimedia Lab.
Número de vídeos	7,442	2,452	720	8,438
Emociones	Enojo, felicidad, tristeza, disgusto, miedo y neutral	Enojo, felicidad, tristeza, neutral, calma, temor, disgusto y sorpresa	Enojo, felicidad, tristeza, miedo, sorpresa y disgusto	Enojo, felicidad, neutral y sorpresa
Número de participantes	91 actores	24 actores profesionales	8 actores	12 actores
Formato de vídeo	MP4	MP4	MP4	MP4
Duración (segundos)	1-4	3-4	4-6	1-8
Anotaciones	Contiene	Contiene	Contiene	Contiene
FPS	30	30	30	30

Las bases de datos contienen una diversidad de emociones; sin embargo, se opta por limitar el análisis exclusivamente a tres: enojo, felicidad y tristeza.

De la Figura 5.1 a la 5.10 se muestran los puntos clave que se establecieron.




Figura 5.1: Primer punto clave.




Figura 5.2: Segundo punto clave.




Figura 5.3: Tercer punto clave.




Figura 5.4: Cuarto punto clave.




Figura 5.5: Quinto punto clave.




Figura 5.6: Sexto punto clave.




Figura 5.7: Séptimo punto clave.




Figura 5.8: Octavo punto clave.




Figura 5.9: Noveno punto clave.




Figura 5.10: Décimo punto clave.

La Figura 5.11 muestra las características en diferentes tiempos de un vídeo, estableciendo 100 frames por característica, se tienen 20 características.




Figura 5.11: Extracción de las 20 características.

Se comprueba que los datos de las características son diferentes de la Figura 5.12 a la 5.31 muestra las discrepancias entre los datos de las tres clases.




Figura 5.12: Primer punto clave ángulo alfa.




Figura 5.13: Primer punto clave ángulo beta.




Figura 5.14: Segundo punto clave ángulo alfa.




Figura 5.15: Segundo punto clave ángulo beta.




Figura 5.16: Tercer punto clave ángulo alfa.




Figura 5.17: Tercer punto clave ángulo beta.




Figura 5.18: Cuarto punto clave ángulo alfa.




Figura 5.19: Cuarto punto clave ángulo beta.




Figura 5.20: Quinto punto clave ángulo alfa.




Figura 5.21: Quinto punto clave ángulo beta.




Figura 5.22: Sexto punto clave ángulo alfa.




Figura 5.23: Sexto punto clave ángulo beta.





Figura 5.24: Séptimo punto clave ángulo alfa. Figura 5.25: Séptimo punto clave ángulo beta.





Figura 5.26: Octavo punto clave ángulo alfa. Figura 5.27: Octavo punto clave ángulo beta.





Figura 5.28: Noveno punto clave ángulo alfa. Figura 5.29: Noveno punto clave ángulo beta.




Figura 5.30: Décimo punto clave ángulo alfa. Figura 5.31: Décimo punto clave ángulo beta.

En las Figuras 5.12 a 5.31 se presenta la variación de los datos, así como la medida de dispersión, que denota la variabilidad de una serie de datos en relación con su media. Los datos superpuestos representan observaciones similares, lo que dificulta a la red neuronal distinguir a que clase pertenecen. En el programa, se exhiben los datos mediante la distancia de los centros, calculándose así el centro medio del conjunto de datos. La Figura 5.32 ilustra la distancia de una característica de 20 de los 1500 datos.

```

Distancia entre enojo y felicidad es 161.89874377989915
Distancia entre enojo y tristeza es 23.164334835482315
Distancia entre felicidad y tristeza es 148.47011410329844

```

Figura 5.32: Distancia entre las 3 clases.

El Cuadro 5.2 muestra los 3 modelos significativos durante el desarrollo llegando al 80 % de exactitud, la red RNN-LSTM, del primer entrenamiento, segundo y tercero en orden descendente, se recuerda que la entrada de la red neuronal son las características, y las salidas son las clases de enojo, tristeza y felicidad. La importancia del modelo radica en saber si este puede aprender los datos de las 3 clases.

Cuadro 5.2: Modelos de las redes neuronales.

Modelo de la red neuronal							
Lote	Neuronas	Capas	Dropout	Datos de entrenamiento	Datos de prueba	Tasa de aprendizaje	Épocas
16	140	2	0.1	1200	300	0.005	10
32	140	2	0.1	1200	300	0.001	100
32	1400	2	0.1	1200	300	0.000001	120

El lote es un subconjunto de los datos que la red utiliza para entrenar en una época. Las neuronas se encargan de pasar los datos para que la red aprenda. Dropout es una técnica de regularización que aleatoriamente elimina neuronas de la red durante el entrenamiento. Esto ayuda a evitar el sobreajuste (overfitting) al evitar que la red se vuelva dependiente de patrones específicos en los datos de entrenamiento. Los datos de entrenamiento son los datos que la red toma para aprender, mientras que los datos de prueba son datos que la red no conoce y se utilizan para probar si esta está aprendiendo con los datos de entrenamiento. El gradiente es una medida de la dirección en la que se debe ajustar un peso para minimizar el error. La tasa de aprendizaje determina qué tan grande es el paso que se toma en esa dirección. Una época es una pasada completa por todo el conjunto de datos de entrenamiento.

Las Figuras 5.33, 5.35 y 5.37 se visualiza el proceso de aprendizaje de los tres modelos distintos mediante los datos de entrenamiento en cada época. Lo óptimo es que el error disminuya con el transcurso del tiempo, tanto en los datos de entrenamiento como en los de prueba. Este conjunto de datos se emplea para evaluar la capacidad de generalización del modelo frente a nuevas observaciones. No se utiliza en el proceso de entrenamiento, sino que se reserva para evaluar el rendimiento del modelo con datos desconocidos.

Las Figuras 5.34, 5.36 y 5.38 se presentan las matrices de confusión que detallan la precisión de cada clase de manera individual, así como la precisión conjunta de las tres clases.




Figura 5.33: Primer aprendizaje.




Figura 5.34: Primera matriz de confusión.




Figura 5.35: Segundo aprendizaje.




Figura 5.36: Segunda matriz de confusión.




Figura 5.37: Tercer aprendizaje.




Figura 5.38: Tercera matriz de confusión

Las Figuras 5.33 a la 5.36, así como la exactitud y la validación, no son buenas debido a que no se utilizan características adecuadas para que la red neuronal identifique los datos de cada clase. Esto sucede porque no se observa el comportamiento de las características, es decir, cómo los datos se dispersan a través de la media. Para verificar la exactitud, se basan en el 20 % de los datos de prueba, siendo 300 datos divididos entre las 3 clases. Por lo tanto, en la matriz de confusión se muestran 100 datos para felicidad, enojo y tristeza. Para verificar esto, se pueden sumar las filas dando un total de 100, que es el número de datos de prueba para cada clase. Estos indican a qué clase pertenecen, mostrando la relación entre clases cuando los datos pertenecen a felicidad con felicidad, enojo con enojo y tristeza con tristeza. La exactitud se valida al sumar los datos que están en la misma clase, en otras palabras, la diagonal de la matriz, y luego se divide entre 3, que es el número de clases.




Figura 5.39: Visualización de datos de prueba en matriz de confusión.




Figura 5.40: Exactitud

Para mejorar la exactitud y la validación se necesitan nuevas características. De los 1500 vídeos. Muestra la Figura 5.38, la exactitud y la validación, un incremento, gracias a la elección de nuevas características con una varianza pequeña y con una mayor distancia entre los centros de las clases.

La implementación del sistema de clasificación de emociones en un equipo informático con cámara web introduce nuevas características y las contrasta con los atributos del modelo previamente entrenado. Basándose en estos datos, se procede a determinar la clasificación emocional correspondiente, ya sea enojo, felicidad o tristeza. A su vez, se vincula el texto 'enojo', 'felicidad' y 'tristeza' con las etiquetas asignadas en nuestro modelo de entrenamiento, que corresponden a 0, 1 y 2, respectivamente.




Figura 5.41: Emoción enojo.



Figura 5.42: Emoción felicidad.



Figura 5.43: Emoción tristeza.

Para llevar a cabo clasificación, se genera la malla facial de Mediapipe a partir del vídeo capturado por la cámara web. Posteriormente, se procede a extraer las mismas características que el modelo entrenado, seguido de una comparación para determinar si el resultado predicho coincide con el resultado deseado del modelo entrenado. Es esencial destacar que la implementación para detectar la emoción puede ejecutarse en la CPU, prescindiendo así de la GPU utilizada durante el entrenamiento. Esto se ilustra en las figuras 5.41, 5.42 y 5.43, las cuales presentan las distintas clasificaciones obtenidas.

Capítulo 6

Conclusiones

La elaboración de esta tesina ha logrado alcanzar el propósito general de desarrollar un sistema de detección de expresiones faciales mediante la utilización de una Red Neuronal Recurrente tipo LSTM (RNN-LSTM). Este sistema es capaz de clasificar las expresiones en emociones de felicidad, enojo y tristeza, brindando a los médicos herramientas complementarias para el diagnóstico a distancia de los pacientes.

Se lleva a cabo un análisis de bases de datos de vídeos con expresiones faciales por actores y actrices, lo que permite la recopilación y organización de 1500 vídeos categorizados en emociones de enojo, felicidad y tristeza. Este procedimiento es crucial para obtener los datos necesarios para el desarrollo del sistema. Se diseña y desarrolla un entorno virtual mediante Anaconda, Navigator y Python, así como librerías clave como Mediapipe, Matplotlib, OpenCV, math y os. Este entorno permite programar un algoritmo que extrae las características de las expresiones faciales y las almacena en vectores etiquetados dentro de un archivo JSON.

Se establece una Red Neuronal Recurrente de tipo memoria a largo plazo a corto plazo (RNN-LSTM) mediante la librería Pytorch. Esta red se entrena con los datos en formato JSON, verificando que los datos con distribución Gaussiana tengan la varianza lo más pequeña posible y una distancia entre ellos lo más grande posible, con el fin de clasificar las emociones con mayor exactitud. Se llevan a cabo diversas pruebas y validaciones en el modelo de RNN-LSTM, lo que permite evaluar y ajustar el rendimiento de la red neuronal, asegurando así su eficacia y precisión en la clasificación de emociones, un paso crucial para su aplicación en la identificación de emociones.

Se implementa el modelo entrenado en una computadora personal sin GPU, utilizando la CPU con los mismos hiperparámetros y generando las mismas características de los mismos puntos clave que se usaron para entrenar la red neuronal LSTM. Se compara el modelo entrenado con los nuevos datos, clasificando los datos en las 3 posibles clases.

El logro de estos objetivos demuestra la oportunidad de explorar nuevas opciones en el diagnóstico y tratamiento de pacientes a través de la informática. Este trabajo no solo contribuye al desarrollo tecnológico en el área de la salud, sino que también establece una base sólida para futuras investigaciones y aplicaciones prácticas en el campo de la inteligencia artificial y el procesamiento de vídeo.

Capítulo 7

Anexo I. Viabilidad y Factibilidad

La tecnología necesaria para detectar y clasificar expresiones faciales a través del aprendizaje automático y la visión por computadora está bien establecida y en uso activo. Las RNN-LSTM son apropiadas para este tipo de tareas, ya que pueden procesar secuencias de datos y tienen la capacidad de recordar información a lo largo del tiempo, lo cual es esencial para la detección de expresiones que varían con el paso del tiempo. La recopilación de 1500 vídeos para entrenar el modelo es un objetivo específico alcanzable, siempre que se tenga acceso a dichos datos o se puedan generar de manera ética y legal.

El diseño y desarrollo de un entorno virtual mediante las herramientas mencionadas (Anaconda Navigator, Python, Mediapipe, Matplotlib, OpenCV, Math, os y Pytorch) es factible, dado que son recursos de código abierto y ampliamente utilizados en la comunidad científica para tareas similares. La supervisión de pruebas y validaciones es un paso habitual en el desarrollo de modelos de aprendizaje automático, y es esencial para ajustar y mejorar la red neuronal. Para ello se necesita considerar todos los elementos que se necesitan para desarrollar el sistema. El cuadro 7.1 indica que el costo total de la implementación del sistema es de \$575,000 pesos mexicanos, y se detalla en los aspectos más relevantes para poder desarrollar el sistema sin contar con ningún ámbito específico.

Cuadro 7.1: Gastos.
Viabilidad y factibilidad

Rubro	Descripción	Costo Anual
Sueldo desarrollador	Sueldo base	\$ 204,000
Oficinas	Renta de oficina	\$180,000
Hardware	Computadoras	\$35,000
Software	Licencias	\$30,000
Materiales de oficina	Impresora	\$5,000
Asesorías	Asesoría legal	\$48,000
Otros gastos	Comida y pasajes	\$73,000

Capítulo 8

Anexo II. Normatividad

La serie IEEE P7000 es una serie de estándares que se centran en la ética de la inteligencia artificial (IA) y brinda directrices para el diseño y desarrollo ético de sistemas de inteligencia artificial (IA).

Este estándar ofrece un marco general para abordar las consideraciones éticas en el diseño y desarrollo de sistemas autónomos e inteligentes, enfocándose en la integración de valores éticos durante todo el ciclo de vida del sistema. Dentro de la serie P7000, se encuentran varios estándares que abordan temas específicos relacionados con la ética de la IA:

- IEEE 7001™: Transparencia de los sistemas de IA.
- IEEE 7002™: Gestión de datos personales.
- IEEE P7003™: Algoritmos para la toma de decisiones, entre otros estándares que tratan la rendición de cuentas, la privacidad y la reducción del sesgo algorítmico.

La serie P7000 se distingue por su enfoque, dado que, a diferencia de otros estándares que se enfocan en la interoperabilidad tecnológica, la funcionalidad, la seguridad y la facilitación del comercio, la serie P7000 aborda cuestiones particulares en la intersección de consideraciones tecnológicas y éticas. Se pretende capacitar a los interesados en el diseño, desarrollo y uso de sistemas autónomos e inteligentes para que prioricen las consideraciones éticas y avancen estas tecnologías para el beneficio de la humanidad. Para satisfacer los estándares éticos de IEEE P7000, el equipo responsable del desarrollo del sistema debería: Incorporar transparencia en el proceso de selección: El sistema debe ser capaz de explicar cómo toma sus decisiones, proporcionando una mayor claridad sobre los criterios utilizados y cómo se aplican en la evaluación de los candidatos. Maneja los datos personales de manera ética: Adopta medidas para asegurar la privacidad y la seguridad de la información de los candidatos, así como obtener el consentimiento adecuado para su utilización. Desarrolla algoritmos de toma de decisiones que minimizan el sesgo: Concibe el sistema con el propósito de prevenir cualquier tipo de discriminación en base a características como el género, la edad o la etnia, en lugar de enfocarse en los requisitos y aptitudes necesarios para el puesto. Asegura la rendición de cuentas: Establece un protocolo para que el sistema sea responsable de sus decisiones, permitiendo la identificación y corrección de posibles errores o sesgos.

Capítulo 9

Anexo III. Hoja técnica

La parte esencial para elaborar este proyecto ha sido la tarjeta gráfica cuando es parte del ordenador y funciona, se asume que posee los recursos de hardware para desarrollar el clasificador.

SPECIFICATIONS

Núcleos	3584
Memoria	12GB GDDR6
Norma Bus	PCI Express® Gen 4
Interfaz de Memoria	192-bit
Velocidad de clock de memoria (MHz)	15 Gbps
Máximo de pantallas	4
Tecnología G-SYNC™	Y
Adaptive Vertical Sync	Y
Tecnología Multi-GPU	Y
Soporte HDCP	Y
Consumo (W)	170W
Apto para Realidad Virtual	Y
Alimentación recomendada (W)	550W
Resolución máxima digital	7680 x 4320
Conectores de alimentación	8-pin x 1
Soporte DirectX Versión	12 API
Soporte OpenGL Versión	4.6
Dimensiones (mm)	235 x 124 x 42 mm
Peso	675 g / 1030 g

CONNECTIONS




Figura 9.1: Especificaciones de la GPU.

Capítulo 10

Anexo IV. Glosario

- Python: Es un lenguaje de programación de alto nivel que se caracteriza por su énfasis en la legibilidad del código. Python es multiparadigma, ya que soporta orientación a objetos, programación imperativa y, en menor medida, programación funcional. Es interpretado, dinámico y multiplataforma.
- JSON (JavaScript Object Notation): Es un formato de texto ligero para el intercambio de datos. JSON se basa en un subconjunto de la notación literal de objetos de JavaScript, pero se utiliza de manera independiente de JavaScript. Es fácil de leer y escribir para humanos y simple de analizar e interpretar para máquinas.
- GPU Nvidia: Unidad de Procesamiento Gráfico de Nvidia, especializada en el procesamiento de gráficos y cálculos paralelos. CPU: Unidad Central de Procesamiento, es el componente principal de una computadora que realiza la mayoría de los cálculos. Librerías: Conjuntos de funciones o procedimientos preescritos que se pueden utilizar en diferentes programas para realizar tareas específicas.
- Framework: Estructura de soporte definida en la que otro proyecto de software puede ser organizado y desarrollado.
- RNN-LSTM: Red Neuronal Recurrente con Memoria a largo plazo a corto plazo, una arquitectura de red neuronal especial para procesar secuencias de datos.
- Cámara web: Dispositivo digital que se conecta a una computadora para capturar y transmitir imágenes a través de Internet.
- Entorno virtual: Espacio generado por computadora donde los usuarios pueden interactuar con objetos digitales.
- IDE Spyder: Entorno de Desarrollo Integrado para Python, orientado a la ciencia de datos y la ingeniería.
- Anaconda Navigator: Interfaz gráfica de usuario que permite gestionar paquetes, entornos y canales conda sin usar comandos de línea.
- Telemedicina: Aplicación de tecnologías de información y comunicación para la prestación de servicios sanitarios a distancia.
- Archivo PTH de PyTorch: En el contexto de PyTorch, un marco de aprendizaje automático, un archivo .pth es un archivo de estado de modelo. PyTorch utiliza estos archivos para guardar y cargar modelos de aprendizaje automático. Un archivo .pth contiene los pesos y sesgos de un modelo entrenado, así como la arquitectura del modelo, si se incluye.

Capítulo 11

Anexo V. Acrónimos

- CENECET: Centro Nacional de Excelencia Tecnológica en Salud.
- CDC: Centros para el Control y Prevención de Enfermedades.
- RNC: Red neuronal convolucional.
- COVID-19: enfermedad por coronavirus de 2019.
- CPU: Unidad Central de Procesamiento.
- GPU: Unidad de Procesamiento Gráfico.
- JSON: Notación de Objetos de JavaScript.
- RAM: Memoria de Acceso Aleatorio.
- RNN-LSTM: Red Neuronal Recurrente de Memoria a Corto y Largo Plazo.
- JAFFE: Expresiones Faciales Femeninas Japonesas.
- MMI: Índice de Madurez del Modelo.
- IA: Inteligencia Artificial.
- SVM: Máquina de Vectores de Soporte.
- RNA: Redes Neuronales Artificiales.
- CREMA-D: Conjunto de Datos Multimodal de Actores Emocionales de Origen Colectivo.
- RAVDESS: Base de Datos Audiovisual de Discurso y Canciones Emocionales de Ryerson.
- MSP-IMPROV: Mejoras en el Procesamiento de Señales Multimodales.
- CUDA: Arquitectura de Dispositivos Unificados de Cálculo.

Capítulo 12

Anexo VI. Línea de tiempo

Se presentan los trabajos recopilados de los últimos cinco años para mostrar los sistemas que existen y en qué están implementados, cómo se desarrollan y los resultados que obtienen a través de sus modelos entrenados con diferentes redes neuronales y qué base de datos utilizan, así como la exactitud de los modelos en diferentes escenarios. Para más información al respecto, se sugiere consultar el capítulo estado del arte.




Figura 12.1: Línea de tiempo.

Capítulo 13

Anexo VII. Cronograma

Se establece un cronograma para obtener un orden y metodología cascada.

Cronograma						
Fecha	Actividad	Introducción	Estado del arte	Marco teórico	Diseño e implementación	Resultados
2023-11-03	Inicio	✓				
2023-11-03- 2023-11-10	Revisión de literatura		✓			
2023-11-11- 2023-11-24	Definición del problema y objetivos			✓		
2023-11-25- 2023-12-08	Diseño de la metodología				✓	
2023-12-09- 2024-01-12	Recolección de datos				✓	
2024-01-13- 2024-02-09	Análisis de datos				✓	
2024-02-10- 2024-03-22	Desarrollo del prototipo				✓	
2024-03-23- 2024-04-05	Pruebas y evaluación del prototipo				✓	
2024-04-06- 2024-05-15	Documentación y presentación de resultados					✓

Cuadro 13.1: Cronograma.

Capítulo 14

Anexo A

14.1. Aceptación de la videoconsulta

La actual digitalización de la atención sanitaria permite que los pacientes reciban tratamiento a través de tecnologías telemédicas, como la videoconsulta (VC), que los médicos generales utilizan cada vez más. En particular, las zonas rurales presentan un rápido envejecimiento de la población, con un aumento de los problemas de salud asociados, mientras que el nivel de atracción para trabajar en esas regiones disminuye para los médicos jóvenes. La integración de enfoques telemédicos en el tratamiento de pacientes puede ayudar a reducir la carga de trabajo profesional y contrarrestar la tendencia hacia la escasez espacial en muchos países. Como resultado, un número cada vez mayor de pacientes se enfrenta a tratamientos digitales y nuevas formas de prestación de atención. Estas nuevas formas de atención generan interacciones con los pacientes y su vida privada de maneras sin precedentes, lo que exige estudios que incorporen las necesidades, expectativas y comportamiento de los pacientes en el diseño y la aplicación de la tecnología telemédica dentro del campo de la atención primaria. La forma en que se perciben las limitaciones y el potencial de la CV varía según los pacientes. A la hora de practicar la CV en atención primaria se deben considerar diferentes aspectos al tratar con pre consumidores, como mantener una interacción física con el médico o incorporar señales sociales. Una vez que se lleva a cabo la intervención digital, los pacientes tienden a valorar beneficios como la flexibilidad y la eficacia por encima de posibles preocupaciones (Mueller, M., Knop, M., Niehaves, B., & Adarkwah, C. C., 2020).

14.2. Anaconda Navigator y Python

Python se ha convertido en uno de los lenguajes de programación más populares para la investigación en la década pasada. Su naturaleza gratuita y de código abierto y su amplia comunidad en línea son algunas de las razones de su éxito. Se pueden encontrar innumerables ejemplos de aumento de la productividad de la investigación gracias a Python, en una gran cantidad de dominios en línea, incluida la ciencia de datos, la inteligencia artificial y la investigación científica. El objetivo de este tutorial es ayudar a los usuarios a comenzar con Python a través de la instalación y configuración, del software Anaconda. El objetivo es encaminar a los usuarios hacia el uso del lenguaje Python mediante preparándolos para escribir su primer guion. Este tutorial está dividido de la siguiente manera: un pequeño introducción a Python, cómo descargar el software Anaconda, los diferentes contenidos que vienen con la instalación y un ejemplo sencillo relacionado con la implementación de un script de Python (Rolon-Mérette, D., Ross, M., Rolon-Mérette, T., & Church, K., 2020).

14.3. Spyder

Spyder es un IDE altamente funcional diseñado específicamente para análisis de los datos. Puede verse como un IDE todo en uno, que contiene un editor para escribir scripts de código, un explorador de variables para. Inspeccionar datos fácilmente, una consola Ipython y mucho más. Él También incluye potentes herramientas para la inspección y depuración de código, lo que permite al usuario analizar el código en su totalidad o en su totalidad. Línea por línea para detectar y corregir errores. La interfaz también es altamente personalizable, permitiéndole elegir cosas como él, disposición de los diferentes paneles e incluso el diseño (Rolon-Mérette, D., Ross, M., Rolon-Mérette, T., & Church, K., 2020).

14.4. Librería Numpy

Potentes matrices n-dimensionales: Rápidos y versátiles, los conceptos de vectorización, indexación y transmisión de NumPy son los estándares de facto de la computación de matrices en la actualidad. Herramientas de computación numérica: NumPy ofrece funciones matemáticas, integrales, generadores de números aleatorios, rutinas de álgebra lineal, transformadas de Fourier y más. Fuente abierta: Distribuido bajo una licencia BSD liberal, NumPy es desarrollado y mantenido públicamente en GitHub por una comunidad vibrante, receptiva y diversa. Interoperable: NumPy admite una amplia gama de plataformas informáticas y de hardware, y funciona bien con bibliotecas distribuidas, de GPU y de matrices dispersas. Intérprete: El núcleo de NumPy es el código C bien optimizado. Disfrute de la flexibilidad de Python con la velocidad del código compilado. Fácil de usar: La sintaxis de alto nivel de NumPy lo hace accesible y productivo para programadores de cualquier nivel o experiencia (NumPy, 2020).

14.5. Librería Pytorch

PyTorch es un marco de aprendizaje automático (ML) de código abierto basado en el lenguaje de programación Python y la biblioteca Torch. Torch es una biblioteca de aprendizaje automático de código abierto que se utiliza para crear redes neuronales profundas, escrita en el lenguaje de programación Lua. Esta es una de las plataformas recomendadas para la investigación de aprendizaje profundo. Este marco tiene como objetivo acelerar el proceso durante el desarrollo y la implementación de prototipos de investigación.

El marco PyTorch admite más de 200 operaciones matemáticas diferentes. PyTorch se está volviendo cada vez más popular porque simplifica la creación de modelos de redes neuronales artificiales. PyTorch es utilizado principalmente por científicos de datos para investigaciones y aplicaciones de inteligencia artificial (IA). PyTorch se publica bajo la licencia BSD modificada. PyTorch fue originalmente un proyecto de pasantía para Adam Paszke. En ese momento, era alumno de Soumith Chintala, uno de los desarrolladores de Torch. Paszke y varios otros trabajaron con desarrolladores de varias universidades y empresas para probar PyTorch. Chintala trabaja actualmente como investigadora en Meta (anteriormente Facebook), que utiliza PyTorch como plataforma subyacente para todas las cargas de trabajo de IA (Yasar, K., and Lewis, S., 2022).

14.6. Librería Matplotlib

Matplotlib es una biblioteca completa para crear visualizaciones estáticas, animadas e interactivas en Python. Matplotlib hace que las cosas fáciles sean fáciles y las difíciles posibles (Matplotlib — visualization with python, 2020).

- Crea gráficos con calidad de publicación.
- Crea figuras interactivas que puedan hacer Zoom, desplazarse y actualizarse.
- Personalice el estilo visual y el diseño.
- Exporte a muchos formatos de archivo.
- Incrustar en JupyterLab y en interfaces gráficas de usuario.
- Utilice una amplia gama de paquetes de terceros creados en Matplotlib.

14.7. Librería OpenCV

OpenCV es una biblioteca libre de visión artificial originalmente desarrollada por Intel. OpenCV significa *Open Computer Vision* (Visión Artificial Abierta). Desde que apareció su primera versión alfa en el mes de enero de 1999, se ha utilizado en una gran cantidad de aplicaciones, y hasta 2020 se la sigue mencionando como la biblioteca más popular de visión artificial. Detección de movimiento, reconocimiento de objetos, reconstrucción 3D a partir de imágenes, son solo algunos ejemplos de aplicaciones de OpenCV.

Su popularidad se debe a que es:

- libre, publicada bajo licencia BSD, que permite que sea usada libremente para propósitos comerciales y de investigación
- multiplataforma, para los sistemas operativos GNU/Linux, Mac OS X, Windows y Android, y para diversas arquitecturas de hardware como x86, x64 (PC), ARM (celulares y Raspberry Pi)
- documentada y explicada: la organización tiene una preocupación activa de mantener la documentación de referencia para desarrolladores lo más completa y actualizada posible, ejemplos de uso de sus funciones y tutoriales accesibles al público no iniciado en visión artificial, además de difundir y fomentar libros y sitios de formación.

Este módulo proporciona varias funciones relacionadas con el tiempo. Para la funcionalidad relacionada, consulte también los módulos `datetime` y `calendar` (Wikipedia contributors, 2012).

14.8. Librería Time

Este módulo siempre está disponible, no todas las funciones están disponibles en todas las plataformas. La mayoría de las funciones definidas en este módulo llaman a funciones C de la biblioteca de la plataforma con el mismo nombre. A veces puede ser útil consultar la documentación de la plataforma, ya que la semántica de estas funciones varía entre plataformas (time, 2024).

14.9. Librería Math

Estas funciones no pueden ser usadas con números complejos; usa las funciones con el mismo nombre del módulo `cmath` si requieres soporte para números complejos. La distinción entre las funciones que admiten números complejos y las que no se hace debido a que la mayoría

de los usuarios no quieren aprender tantas matemáticas como se requiere para comprender los números complejos. Recibir una excepción en lugar de un resultado complejo permite la detección temprana del número complejo inesperado utilizado como parámetro, de modo que el programador pueda determinar cómo y porque se generó en primer lugar. Este módulo proporciona las funciones descritas a continuación. Excepto cuando se indique lo contrario explícitamente, todos los valores retornados son flotantes (math, 2024).

14.10. Librería os

Este módulo provee una manera versátil de usar funcionalidades dependientes del sistema operativo. Si se quiere leer o escribir un archivo, se puede mirar `open()`, si se quiere manipular rutas, se puede mirar el módulo `os.path`, y si se quiere leer todas las líneas en todos los archivos en la línea de comandos, se puede mirar el módulo `fileinput`. Para crear archivos temporales y directorios, se puede mirar el módulo `tempfile`, y para el manejo de alto nivel de archivos y directorios, se puede ver el módulo `shutil` (os— Interfaces misceláneas del sistema operativo — documentación de Python - 3.10.11. 2023.).

Notas sobre la disponibilidad de estas funciones:

- El diseño de todos los módulos incorporados de Python dependientes del sistema operativo es tal que, mientras la funcionalidad esté disponible, usa la misma interfaz; por ejemplo, la función `os.stat(path)` retorna estadísticas sobre la ruta (`path`) en el mismo formato (lo que sucede originalmente con la interfaz POSIX)
- Las extensiones propias de un sistema operativo en particular también están disponibles a través del módulo `os`, pero usarlas, por supuesto, es un riesgo a la portabilidad.
- Todas las funciones que aceptan rutas o nombres de archivos aceptan bytes o cadenas de texto, y el resultado es un objeto del mismo tipo, siempre que se retorna una ruta o un archivo.

14.11. Librería JSON

En la práctica, `.json` es un archivo que contiene una serie de datos estructurados en formato de texto y se usa para transferir información entre sistemas. Es importante decir que, a pesar de su origen estar en el lenguaje JavaScript, JSON no es un lenguaje de programación. JSON es una notación para la transferencia de datos que sigue un estándar específico. Por eso, puede emplearse en diferentes lenguajes de programación y de sistemas. Los datos contenidos en un archivo en formato JSON deben estructurarse por medio de una colección de pares con nombre y valor o deben ser una lista ordenada de valores. Sus elementos tienen que contener: Clave: corresponde al identificador del contenido. Por eso, debe ser una string delimitada por comillas. Valor: representa el contenido correspondiente y puede contener los siguientes tipos de datos: string, array, object, number, boolean o null (Rock Content, 2021).

14.12. Librería scikit-learn

Es una librería que se puede utilizar en Python y contiene las siguientes herramientas para tener facilidad de analizar datos (scikit-learn, 2019).

- Herramientas sencillas y eficientes para el análisis de datos predictivos.
- Accesible para todos, y reutilizable en varios contextos.
- Construido en NumPy, SciPy y matplotlib.
- Fuente abierta, comercialmente utilizable - licencia BSD.
- Clasificación Identificar a qué categoría pertenece un objeto. aplicaciones: detección de correo no deseado, reconocimiento de imágenes. algoritmos: el impulso gradiente, vecinos más cercanos, bosque aleatorio, regresión logística, y más.
- Regresión Predecir un atributo de valor continuo asociado a un objeto. aplicaciones: respuesta a los medicamentos, precios de las acciones. algoritmos: el impulso gradiente, vecinos más cercanos, bosque aleatorio, - cindí, y más.
- Agrupación automática de objetos similares en conjuntos. aplicaciones: Segmentación del cliente, Agrupar resultados del experimento, algoritmos: k-Means, HDBSCAN, jerárquico, agrupación, y más.
- Selección de modelos Comparación, validación y elección de parámetros y modelos. Aplicaciones: Mejora de la precisión mediante afinación de parámetros Algoritmos: Búsqueda de cuadrícula, validación cruzada, métricas, y más.

14.13. MediaPipe

MediaPipe consta de tres partes principales:

- Un marco para inferencias a partir de datos sensoriales.
- Un conjunto de herramientas de evaluación del desempeño.
- Una colección de inferencias reutilizables y componentes de procesamiento.

Aquí cada componente es una computadora. Los desarrolladores pueden definir calculadoras personalizadas. Las descripciones de gráficos se especifican a través del búfer del protocolo GraphConfig y se realizan utilizando objetos Graph. En el diagrama, los datos sobre datos fluyen a través de cada computadora corriente. La unidad básica de datos en MediaPipe es un paquete. Un flujo transporta una serie de paquetes con marcas de tiempo que aumentan monótonamente. Las computadoras y el equipo de transmisión definen juntos un diagrama de flujo de datos. Cada flujo en el gráfico mantiene su propia cola para que los nodos receptores del gráfico puedan consumir paquetes a su propio ritmo (Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M. & Grundmann, M. 2019).

14.14. Unidad de procesamiento de gráficos

En los últimos años, ha surgido la posibilidad de utilizar Unidades de Procesamiento Gráfico (GPU) para cálculos científicos. Mucho interés. Una tecnología desarrollada inicialmente para hardware de PC doméstico ha evolucionado rápidamente en la dirección de la producción. Procesador de streaming paralelo gramable. Las características de estos dispositivos, en particular su precio muy bajo y su rendimiento. Relación, junto con el consumo de energía relativamente bajo, los convierten en plataformas atractivas para investigaciones científicas intensivas. Cálculos recientemente, se han portado muchas aplicaciones científicas a GPU, incluida, por ejemplo, la investigación molecular, dinámica, Monte-Carlo, cuántico método de elementos finitos. En el dominio del cálculo de estructuras electrónicas, el cálculo del término de correlación de intercambio en un código DFT basado en Gauss se ha implementado en GPU, así como la evaluación del potencial de Coulomb. También el cálculo de campo autoconsistente del método gaussiano. El código GAMESS fue portado a GPU. La mayoría de estas implementaciones se realizan mediante cálculos de precisión simple, unidades, y con un solo núcleo de CPU conectado a una sola tarjeta GPU. En este artículo presentaremos una implementación de un código DFT completo que puede ejecutarse en híbridos paralelos masivos. Clústeres CPU-GPU. Nuestra implementación se basa en la arquitectura de las tarjetas GPU NVidia más recientes, que admite números de coma flotante de doble precisión. Las rutinas que definen la GPU. Por lo tanto, los núcleos están codificados dentro de la especificación del lenguaje CUDA. El código DFT que se basa en de nuestra implementación es un código sistemático basado en wavelets de Daubechies (Genovese, L., Ospici, M., Deutsch, T., Méhaut, J.-F., Neelov, A., & Goedecker, S., 2009).

14.15. CUDA

El sistema de herramientas NVIDIA CUDA proporciona un entorno de desarrollo para la creación de aplicaciones aceleradas de alto rendimiento y GPU. Con él, puede desarrollar, optimizar e implementar sus aplicaciones en sistemas integrados acelerados por GPU, estaciones de trabajo de escritorio, centros de datos empresariales, plataformas basadas en la nube y superordenadores. El conjunto de herramientas incluye bibliotecas aceleradas por GPU, herramientas de depuración y optimización, un compilador de C/C y una biblioteca de tiempo de ejecución (CUDA Toolkit, 2007).

14.16. Distribución Gaussiana

Se dice que muchos fenómenos se distribuyen normalmente. Esto significa que si uno toma al azar un número suficientemente grande de casos y construye un polígono de frecuencias con alguna variable continua, por ejemplo peso, talla, presión arterial o temperatura, se obtendrá una curva de características particulares, llamada distribución normal. Es la base del análisis estadístico, ya que en ella se sustenta casi toda la inferencia estadística. La función de densidad de probabilidad para la variable aleatoria continua fue descubierta por Carl Gauss al estudiar el comportamiento de los procesos aleatorios. Es ampliamente utilizada en estadística y teoría de las probabilidades. La función de densidad de probabilidad para la variable aleatoria continua fue descubierta por Carl Gauss al estudiar el comportamiento de los procesos aleatorios. Es ampliamente utilizada en estadística y teoría de las probabilidades. Esta función, también conocida como distribución normal, tiene la forma de una campana, por este motivo también es conocida como la campana de Gauss. Sus características son las siguientes (José Espinosa, 2016):

- Es una distribución simétrica.
- Es asintótica, sus extremos nunca tocan el eje horizontal, cuyos valores tienden a infinito.
- En el centro de la curva se encuentran la media, la mediana y la moda.
- El área total bajo la curva representa el 100 % de los casos.
- Los elementos centrales del modelo son la media y la varianza.

Capítulo 15

Anexo B

15.1. Bases de datos

La información obtenida del Cuadro 5.1 se puede consultar en los siguientes enlaces:

- CREMA-D: <https://paperswithcode.com/dataset/crema-d>
- RAVDESS: <https://paperswithcode.com/dataset/ravdess>
- Ryerson Emotion: <https://www.kaggle.com/datasets/ryersonmultimedialab/ryerson-emotion-database/data>
- MSP-IMPROV: <https://ecs.utdallas.edu/research/researchlabs/msp-lab/MSP-Improv.html>

Capítulo 16

Referencias

Sultana, A., Dey, S. K., & Rahman, M. A. (2021, November). A Deep CNN based Kaggle Contest Winning Model to Recognize Real-Time Facial. Expression. In *2021 5th International Conference on Electrical Engineering and Information Communication Technology (ICEEICT)* (pp. 1-5). IEEE.

Kallipolitis, A., Galliakis, M., Menychtas, A., & Maglogiannis, I. (2019, May). Emotion analysis in hospital bedside infotainment platforms using speeded up robust features. In *IFIP International Conference on Artificial Intelligence Applications and Innovations* (pp. 127-138). Cham: Springer International Publishing.

Muhammad, G., & Hossain, M. S. (2021). Emotion recognition for cognitive edge computing using deep learning. *IEEE Internet of Things Journal*, 8(23), 16894-16901.

Mueller, M., Knop, M., Niehaves, B., Adarkwah, C. C. (2020). Investigating the acceptance of video consultation by patients in rural primary care: empirical comparison of preusers and actual users. *JMIR medical informatics*, 8(10), e20813.

Rolon-Mérette, D., Ross, M., Rolon-Mérette, T., & Church, K. (2020). Introduction to Anaconda and Python: Installation and setup. *The Quantitative Methods for Psychology*, 16(5), S3-S11. <https://doi.org/10.20982/tqmp.16.5.s003>

Rouhiainen, L. (2018). Inteligencia artificial. *Madrid: Alienta Editorial*. Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., ... & Grundmann, M. (2019). Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*.

Pinzón Montes, Q. A., Lazcano Salas, S., Orozco Aguirre, H. R., Quintana Lopez, M. (2021). Detección automatizada de emociones a través del rostro, una revisión del estado del arte. <https://ri.uaemex.mx/handle/20.500.11799/112586>

Menacho Chiok, C. H. (2014). Modelos de regresión lineal con redes neuronales. *Anales Científicos*, 75(2), 253-260.

Bengio, Y., Simard, P., Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5(2), 157-166. <https://doi.org/10.1109/72.279181>

Bengio, Y., Léonard, N., Courville, A. (2013). Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*.

Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735-1780.

Bitzel Cortez, Jae-Yoon Jung, Young-Jin Kim, & Berny Carrera, Eds, (2017, December 20). An architecture for emergency event prediction using LSTM recurrent neural networks. [Review of An architecture for emergency event prediction using LSTM recurrent neural networks]. *Sciendo*.

Vergara, Sebastián & Farias, Gonzalo & Fabregas, Ernesto & Dormido-Canto, s & Vega, Jesús. (2019). Preliminary results on anomaly detection in nuclear fusion with Deep Learning.

NumPy, 2024. Numpy.org. Recuperado el 22 de diciembre de 2023, de <https://numpy.org/>

Yasar, K., and Lewis, S. (2022, noviembre 16). PyTorch. Enterprise AI; TechTarget.

Kinza Yasar, (2022), Definition PyTorch, consultado en: <https://www.techtarget.com/searchenterpriseai/definition/PyTorch>

Matplotlib — visualization with python, (2020). Matplotlib.org. Recuperado el 22 de diciembre de 2023, de <https://matplotlib.org/>

Wikipedia contributors. (2012). OpenCV. Wikipedia, The Free Encyclopedia. <https://es.wikipedia.org/wiki/OpenCV>

time — Acceso a tiempo y conversiones. (2024). Python Documentation. [https:// docs.python.org/es/3/library/time.html](https://docs.python.org/es/3/library/time.html)

math — Funciones matemáticas — documentación de Python - 3.10.13. (2023). Docs.python.org. Retrieved March 20, 2024, from <https://docs.python.org/es/3.10/library/math.html>

os — Interfaces misceláneas del sistema operativo — documentación de Python - 3.10.11. (2023). Docs.python.org. <https://docs.python.org/es/3.10/library/os.html>

Rock Content, 2021. Archivo Json: descubre qué es y para qué sirve. - ES. <https://rockcontent.com/es/blog/archivo-json/>

scikit-learn: machine learning in Python. (2019). Scikit-Learn.org. <https://scikit-learn.org/stable/>

Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., ... & Grundmann, M. (2019). Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*.

Genovese, L., Ospici, M., Deutsch, T., Méhaut, J.-F., Neelov, A., Goedecker, S. (2009). Density functional theory calculation on many-cores hybrid central processing unit-graphic processing unit architectures. *The Journal of Chemical Physics*, 131(3), 034103. <https://doi.org/10.1063/1.3166140>

CUDA Toolkit. (2007). NVIDIA Developer. Recuperado el 20 de mayo de 2024, de <https://developer.nvidia.com/cuda-toolkit>.

José Manuel Becerra Espinosa. (2016). Unam.Mx. Recuperado el 29 de abril de 2024, de http://prepa8.unam.mx/academia/colegios/matematicas/paginacolmate/applets/matematicas_vI12/AppletsGeogebra/disnormal.html

CENETEC. “Reportes de acciones de Telesalud – Observatorio de Telesalud”. Observatorio de Telesalud – CENETEC Salud. Accedido el 20 de febrero de 2024. [En línea]. Disponible: https://cenetecdifusion.com/observatoriotelesalud/acciones_telesalud/

A. Daly Aurenty, 2022. “Telemedicina: cifras importantes de su impacto en la sociedad”. BBVA.CH. Accedido el 19 de febrero de 2024. [En línea]. Disponible: <https://www.bbva.ch/noticia/telemedicina-cifras-importantes-de-su-impacto-en-la-sociedad/>

ACHS, 2012. Los efectos del enojo en la salud, consultado en: <https://www.achs.cl/centro-de-noticias/noticia/2012/los-efectos-del-enojo-en-la-salud>

Lupayante, O. Z. M., 2016. ¿Cuáles son los efectos de la tristeza en tu cuerpo? Mejor Con Salud. <https://mejorconsalud.as.com/cuales-son-los-efectos-de-la-tristeza-en-tu-cuerpo/>